تاثیر پردازش و مقایسه بین حالت اول و دوم:

در وهله اول می‌توان به تاثیر پردازش‌ها در حجم ذخیره‌سازی برای دیکشنری و posting listها اشاره کرد که با انجام پردازش‌ها این حجم‌ها تا ۱۳٪ کاهش ایجاد کرد

این پردازش‌ها شامل حذف انواع کاراکترهای نیم‌فاصله که باعث یکسان‌تر شدن نوشتار واژه‌ها می‌شود و حذف اعداد و حذف حروف انگلیسی و حذف علائم نگارشی و حذف ایموجی‌ها هست که شاید خیلی در تعریف مسئله ما مورد اهمیت نباشد و باعث کاهش حجم و بهتر شدن نتایج برگردانده شده می‌شود و حذف انواع اعراب و یکسان‌سازی اشکال متفاوت نوشتاری حروف که باعث می‌شود تا برای برگرداندن نتیجه مجموعه‌ای از اسناد را به خاطر اشکال متفاوت نگارشی از دست ندهیم و بتوانیم نتیجه کامل‌تر و بهتری رو برگردونیم و ریشه‌یابی کلمات که باعث می‌شود افعال را فارغ از شناسه و ضمایر آن‌ها و کلمات را بدون توجه به جمع یا مفرد بودن نگاه کنیم تا بتونیم نتایج بیشتر و بهتری داشته باشیم

حال به بررسی تعدادی مثال برای مقایسه بین حالت اول و دوم می‌پردازیم:

- جعبه چوبی
  - جعبه‌ی چوبی: خالی
  - جعبه چوب: 7498, 11570, 11812, 31369, 34196, 41222, 49955
- خبرگزاری‌ها گفتند
  - خبرگزاری‌ها گفتند: 7663, 27906, 32026, 33726, 35026
  - خبرگزاری: 0, 2, 7, 8, 13, 14, 16, 24, 27, 28, 29, 34, 36, 37, 38, 39, 41, 44, 45, …
- خبرگذاری‌ها گفتند
  - خبرگذاری‌ها گفتند: خالی
  - خبرگذاری: 52870, 53970
- خانه‌ی کلنگی
  - خانه‌ی کلنگی: خالی
  - خانه کلنگ: 971, 1500, 3711, 4900, 4963, 9249, 10168, 10463, 11324, 14587, …
- مسأله
  - مسأله: 85, 464, 790, 892, 1182, 1252, 1290, 1534, 2063, 2144, 2283, 2608, …
  - مساله: 62, 69, 85, 94, 111, 188, 233, 464, 564, 666, 740, 790, 892, 894, …
- می‌گذارد
  - می‌گذارد: 25, 119, 280, 288, 372, 571, 685, 923, 934, 950, 985, 1083, 1135, …
  - گذار: 22, 25, 39, 51, 63, 69, 92, 93, 108, 111, 119, 120, 121, 129, 142, 152, …
- می گذارد
  - گذارد: 180, 370, 668, 1145, 1210, 1466, 1666, 1827, 2265, 2336, 2372, 2381, …
  - گذار: 22, 25, 39, 51, 63, 69, 92, 93, 108, 111, 119, 120, 121, 129, 142, 152, …

در مثال‌های ذکر شده می‌توان دید که پردازش‌ها باعث پیدا کردن اسناد بیشتری به ازای هر پرسمان شده است و تا حدی برای پرسمان‌های غیرمعمول مثل «خبرگذاری‌ها گفتند» بتونیم نتایجی رو برگردونیم یا در مثال «مسأله» بتونیم اسنادی که شامل اشکال نوشتاری متفاوتی از این کلمه هست را هم برگردانیم یا در مثال‌های «می‌گذارد» یا «می گذارد» اسنادی که شامل این فعل با شناسه یا ضمایر متفاوت هست را هم برگردانیم

نرمال‌سازی:
برای این قسمت تابع‌های زیر پیاده‌سازی کردم:
- remove_half_spaces: برای حذف نیم‌فاصله‌ها
- remove_numbers: برای حذف ارقام
- remove_english_characters: برای حذف حروف انگلیسی
- remove_punctuations: برای حذف علائم نگارشی
- remove_diacritics: برای حذف اعراب و تبدیل نوشتارهای متفاوت حروف
- remove_emojis: برای حذف ایموجی‌ها
- replace_multi_words_token: برای تبدیل عبارت‌های ترکیبی

استخراج توکن‌ها:
برای این بخش در حالت اول بعد حذف کاراکترهای اضافی کلمات را بر اساس فاصله از هم جدا می‌کنم و توکن‌ها رو تولید می‌کنم و در حالت دوم از tokenizer کتابخانه hazm استفاده می‌کنم تا بهتر و با معنی‌تر توکن‌ها را استخراج کنیم

استخراج خودکار عبارت‌های ترکیبی پرکاربرد:
برای این کار می‌توان در حین ساختن شاخص همه زوج کلماتی که پشت هم ظاهر شده‌اند را بر اساس تعداد وقوع آن‌ها در تمامی اسناد از زیاد به کم مرتب کنیم و سپس با شروع از ابتدا و کنار گذاشتن زوج‌هایی که مثلا حاصل از ترکیب یک حرف اضافه با یک کلمه دیگر هست به عبارت‌هایی ترکیبی برسیم و لیستی از آن‌ها درست کنیم

ریشه‌یابی کلمات:
برای پیاده‌سازی این بخش به صورت ترکیبی از کتابخانه‌های hazm و parsivar استفاده کردیم بدین شکل که ابتدا کلمه را با hazm می‌دهم و سپس خروجی را به parsivar می‌دهم چون هر کدام از این کتابخانه‌ها یک سری از کلمات را نمی‌توانستند ریشه‌یابی کنند اما ترکیب آن‌ها تا حدی خوبی متناسب با کلمات و نیاز ما بود
لیست کلماتی که با ریشه‌یابی به یکی از کلمات ذکر شده تبدیل شده‌اند را می‌توانید در فایل stemming_words.json فایل‌های پروژه ببینید

قوانین Heaps و Zipf:
برای قانون Heaps می‌توان گفت حالت دوم بیشتر از اول در این قانون صادق که دلیل آن هم اشکال متفاوتی نوشتاری توکن‌ها در دیکشنری در حالت اول هست اما در حالت دوم با توجه به

نمودارهای زیر می‌توان گفت به میزان خوبی قانون Heaps برقرار است و از طرف دیگر هم می‌توان گفت بهترین برازش خطی در حالت دوم خط y=0.49x+1.60 هست که تا حد زیادی منطبق بر قانون Heaps هست

- حالت اول

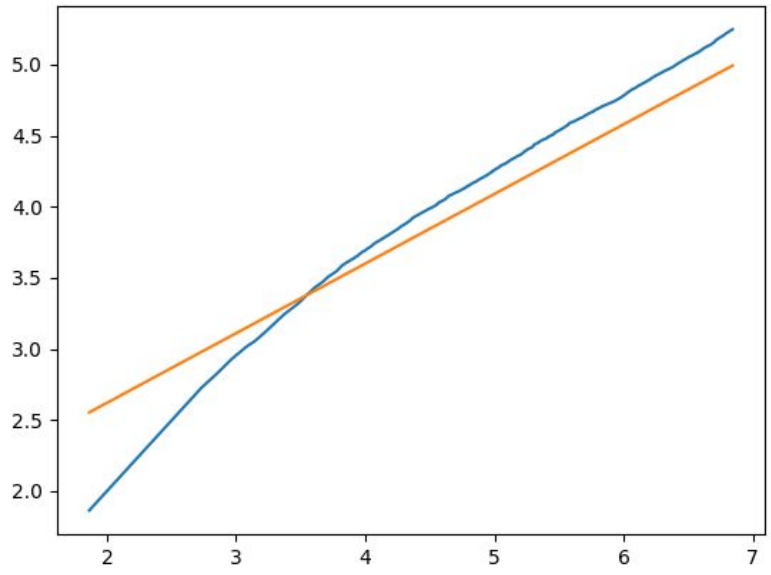

- حالت دوم

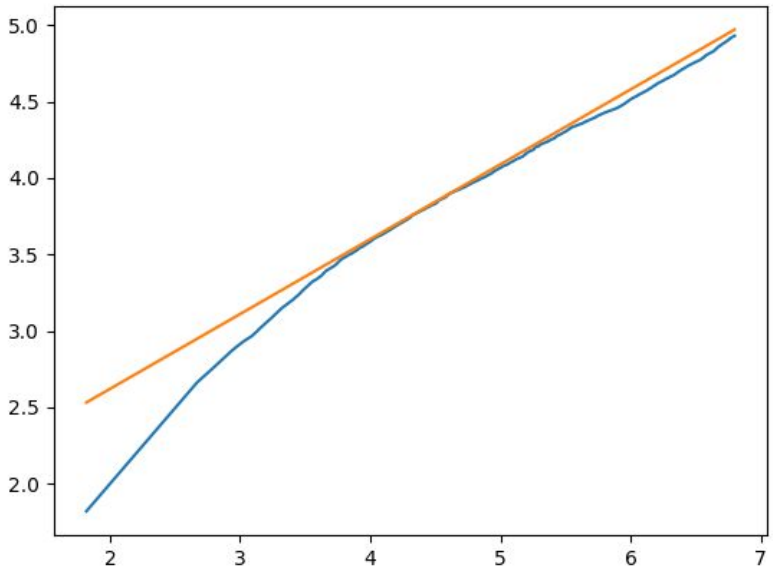

برای قانون Zipf می‌توان گفت که در هیچ کدام از یک حالت‌ها چندان برقرار نیست و فکر می‌کنم شاید به خاطر درنظر گرفتن مجموعه به نسبت بزرگی برای stopwordها باعث این اتفاق شده باشد چون حذف این کلمات باعث کاهش اندازه اولین کلمه یا همان K ثابت باشد و به همین دلیل در کل بالای نمودار تخمین Zipf باشیم

- حالت اول

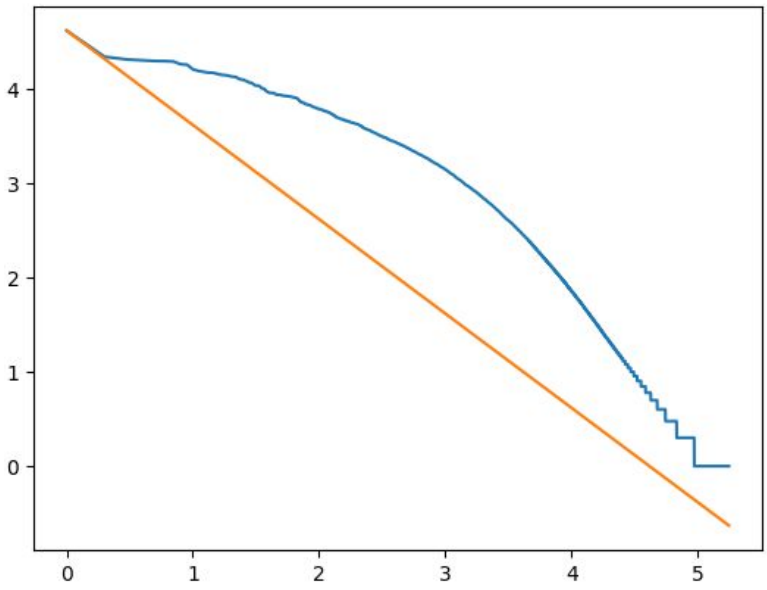

- حالت دوم